

# Análisis Secundario I: Variant Calling

Sara Monzón

BU-ISCIII


Unidades Científico Técnicas – SGAFI-ISCIII

08-12 Junio 2025, 12ª Edición  
Programa Formación Continua, ISCIII

# Índice

- Dónde estamos
- ¿Qué es llamada a variantes?
- Problemas que nos encontramos
- Software de variant calling
- Formatos: vcf y bed
- Anotación y filtrado
- Ejemplos de llamada a variantes:
  - Cáncer
  - Trío
  - Bacterias


## Dónde estamos



## ¿Qué es llamada a variantes?

- El concepto de la llamada a variantes es sencillo:
  - Encontrar posiciones en nuestras secuencias que sean diferentes a referencia -
- A partir de nuestras secuencias mapeadas en el genoma, se recorre cada columna del alineamiento y se cuentan cuántos alelos se encuentran y se comparan con la referencia.

## ¿Qué es la llamada a variantes?



## Problemas que nos encontramos

- Preparación de la librería
- Errores en la secuenciación
- Errores de alineamiento
- Fiabilidad de la referencia

## Problemas que nos encontramos

- Artefactos en la preparación de la librería
  - Mutaciones inducidas por PCR
    - Duplicados
    - Errores a final de la lectura
  - Contaminaciones


## Problemas que nos encontramos

- Ratio de error asociado con la secuenciación.
- Soluciones:
  - Evaluación de Phred
  - Strand bias




# Problemas que nos encontramos

## • Problemas de alineamiento



## Problemas que nos encontramos


- Problemas de alineamiento



## Problemas que nos encontramos

- Fiabilidad del genoma de referencia.
  - Ejemplo genoma humano:
    - Genoma obtenido de mezcla de 8 personas diferentes (Watson entre ellos)
    - Genoma haploide para individuo diploide.
    - Zonas de baja complejidad
    - Incompleto

## Principales software de variant calling



## Formatos: vcf y bed

### • Formato vcf

**VCF header**

```

##fileformat=VCFv4.0
##fileDate=20100707
##source=VCFtools
##reference=NCBI36
##INFO=<ID=AA,Number=1,Type=String,Description="Ancestral Allele">
##INFO=<ID=H2,Number=0,Type=Flag,Description="HapMap2 membership">
##FORMAT=<ID=GT,Number=1,Type=String,Description="Genotype">
##FORMAT=<ID=GQ,Number=1,Type=Integer,Description="Genotype Quality (phred score)">
##FORMAT=<ID=GL,Number=3,Type=Float,Description="Likelihoods for RR,RA,AA genotypes (R=ref,A=alt)">
##FORMAT=<ID=DP,Number=1,Type=Integer,Description="Read Depth">
##ALT=<ID=DEL,Description="Deletion">
##INFO=<ID=SVTYPE,Number=1,Type=String,Description="Type of structural variant">
##INFO=<ID=END,Number=1,Type=Integer,Description="End position of the variant">

```

**Mandatory header lines**

**Optional header lines** (meta-data about the annotations in the VCF body)

**Body**

| #CHROM | POS | ID  | REF | ALT   | QUAL | FILTER | INFO               | FORMAT   | SAMPLE1  | SAMPLE2 |
|--------|-----|-----|-----|-------|------|--------|--------------------|----------|----------|---------|
| 1      | 1   | .   | ACG | A,AT  | .    | PASS   | .                  | GT:DP    | 1/2:13   | 0/0:29  |
| 1      | 2   | rs1 | C   | T,CT  | .    | PASS   | H2;AA=T            | GT:GQ    | 0 1:100  | 2/2:70  |
| 1      | 5   | .   | A   | G     | .    | PASS   | .                  | GT:GQ    | 1 0:77   | 1/1:95  |
| 1      | 100 | .   | T   | <DEL> | .    | PASS   | SVTYPE=DEL;END=300 | GT:GQ:DP | 1/1:12:3 | 0/0:20  |

**Reference alleles (GT=0)**

**Alternate alleles (GT>0 is an index to the ALT column)**

**Deletion**

**SNP**

**Large SV**

**Insertion**

**Other event**

**Phased data** (G and C above are on the same chromosome)

## Formatos: vcf y bed

### • Formato bed

- Se utiliza para representar regiones y/o posiciones

| chromosom | start     | en        | score | name | strand | thickstart | thickend  | RGB     |
|-----------|-----------|-----------|-------|------|--------|------------|-----------|---------|
| chr7      | 127471196 | 127472363 | Pos1  | 0    | +      | 127471196  | 127472363 | 255,0,0 |
| chr7      | 127472363 | 127473530 | Pos2  | 0    | +      | 127472363  | 127473530 | 255,0,0 |
| chr7      | 127473530 | 127474697 | Pos3  | 0    | +      | 127473530  | 127474697 | 255,0,0 |
| chr7      | 127474697 | 127475864 | Pos4  | 0    | +      | 127474697  | 127475864 | 255,0,0 |
| chr7      | 127475864 | 127477031 | Neg1  | 0    | -      | 127475864  | 127477031 | 0,0,255 |
| chr7      | 127477031 | 127478198 | Neg2  | 0    | -      | 127477031  | 127478198 | 0,0,255 |
| chr7      | 127478198 | 127479365 | Neg3  | 0    | -      | 127478198  | 127479365 | 0,0,255 |
| chr7      | 127479365 | 127480532 | Pos5  | 0    | +      | 127479365  | 127480532 | 255,0,0 |
| chr7      | 127480532 | 127481699 | Neg4  | 0    | -      | 127480532  | 127481699 | 0,0,255 |

OBLIGATORIOS

Curso iniciación NGS

OPCIONALES

## Formatos: vcf y bed

- Formato bed
  - Se utiliza para representar regiones y/o posiciones
  - Consideraciones para representar variantes.
  - Utiliza coordenadas 0-based para el inicio y 1-based para el final
  - De manera que la primera base del cromosoma 1 sería:

```
chr1    0    1    first_base
```



## Formatos: vcf y bed

- Ejemplo de formato bed de variantes:

|      |           |           |   |   |
|------|-----------|-----------|---|---|
| chr1 | 100154496 | 100154497 | A | G |
| chr1 | 100182982 | 100182983 | C | T |
| chr1 | 100195206 | 100195207 | C | A |
| chr1 | 1002596   | 1002597   | C | A |
| chr1 | 100343384 | 100343385 | G | T |
| chr1 | 10041131  | 10041132  | C | A |
| chr1 | 100575981 | 100575982 | G | T |
| chr1 | 100621863 | 100621864 | G | T |
| chr1 | 100672062 | 100672063 | C | T |
| chr1 | 10067673  | 10067674  | G | T |
| chr1 | 100733834 | 100733835 | G | T |
| chr1 | 101007160 | 101007161 | G | T |
| chr1 | 101186145 | 101186146 | G | T |
| chr1 | 101376658 | 101376659 | C | A |
| chr1 | 101379322 | 101379323 | C | A |
| chr1 | 101490740 | 101490741 | G | T |
| chr1 | 10161234  | 10161235  | G | A |
| chr1 | 101705323 | 101705324 | C | A |
| chr1 | 101705774 | 101705775 | C | A |
| chr1 | 10179467  | 10179468  | C | A |
| chr1 | 10197177  | 10197178  | C | G |
| chr1 | 10197185  | 10197186  | G | T |

Esta es la posición donde se encuentra la variante


Admite prácticamente de todo

En este caso Alelo alternativo y Alelo referencia

Obligatorios



## Anotación y Filtrado



## Anotación y filtrado

- Anotación:

- A nivel de gen: se anota gen y “feature” según la base de datos refgene (variante tipo missense, frameshit, intron, etc.)
- Anotación de variantes no sinónimas: dbNSFP

- |                    |                           |
|--------------------|---------------------------|
| • SLR              | • FATHMM_score            |
| • SIFT             | • CADD_score              |
| • Polyphen2_HDIV   | • GERP++_NR               |
| • Polyphen2_HVAR   | • GERP++_RS               |
| • LRT              | • PhyloP100way_vertebrate |
| • Mutation Taster  | • 29way_logOdds           |
| • Mutation Assesor |                           |

- A nivel funcional: pseudogenes, UniprotFeature, etc.
- A nivel de enfermedad: anotación de enfermedad asociada con ese gen en OMIM


## Ejemplo de variant calling: Cáncer

- Software específico para comparaciones tumor-control


|                      | Samtools | GATK          | VarScan 2     | Somatic Sniper | JointSN Vmix | Strelka        | LoFreq     | MuTect         | Shimmer      | EBCalling       | Virmid    |
|----------------------|----------|---------------|---------------|----------------|--------------|----------------|------------|----------------|--------------|-----------------|-----------|
| Publication          | Li et al | McKenna et al | Koboldt et al | Larson et al   | Roth et al   | Saunders et al | Wilm et al | Cibulski et al | Hansen et al | Shiraishi et al | Kim et al |
| Year                 | 2009     | 2010          | 2012          | 2012           | 2012         | 2012           | 2012       | 2013           | 2013         | 2013            | 2013      |
| Model                | Bayesian | Bayesian      | Fisher test   |                | Prob         | Bayesian       | Binomial   | Bayesian       |              | Bayesian        | Prob      |
| Programming language | C        | java          | Java, perl    | C              | python       | perl           | C,python   | java           | perl         | Perl,c,R        | Bayesian  |
| Paired sample        | No       | No            | Yes           | Yes            | Yes          | Yes            | Yes        | Yes            | Yes          | Yes             | Yes       |
| Realignment          | No       | Yes           | No            | No             | No           | Yes            | No         | Yes            | No           | No              | No        |

## Ejemplo de variant calling: Cáncer

- Teoría de la llamada a variantes en cáncer




# Ejemplo de variant calling: Cáncer



## Ejemplo de variant calling: Cáncer

- Problemas añadidos a la llamada a variantes
  - Heterogeneidad tumoral




## Ejemplo de variant calling: Cáncer

- Comparativa de distintos software de llamada a variantes en cáncer
  - Evaluar la mejor opción
  - Plantearse seleccionar la intersección de varios.
  - Caracterizar su comportamiento frente a cobertura y frecuencia del alelo alternativo.

# Ejemplo de variant calling: Cáncer


- Problemas de no detectar verdaderas mutaciones somáticas






# Ejemplo de variant calling: Cáncer

- Problemas de realineamiento




## Ejemplo de variant calling: Cáncer

| Library | Starting DNA (μg) | Fragment Size (bp) | Size selection                   | Library protocol | PCR cycles | Sequencing machine                | Chemistry (Illumina) | Depth (×) control:tumour |
|---------|-------------------|--------------------|----------------------------------|------------------|------------|-----------------------------------|----------------------|--------------------------|
| LA      | 4                 | ~400               | 2% Agarose gel                   | KapaBio          | 0          | HiSeq 2500<br>HiSeq 2000<br>MiSeq | V1 (RR)<br>V3<br>V2  | 29.6 : 40.5              |
| LB      | 1                 | ~400               | 2% Agarose gel, Invitrogen E-gel | TrueSeq DNA      | 10         |                                   |                      |                          |
| LC      | 2.5               | ~500               | 2% Agarose gel                   | NEBNext          | 12         |                                   |                      |                          |
| LD      | 1                 | ~550               | Agarose gel                      | TrueSeq DNA      | 10         |                                   |                      |                          |
| LE      | 2.8               | ~620               | 1.5% Agarose gel pippin          | NEBNext          | 0          |                                   |                      |                          |
| LF      | 1                 | ~400               | AMPureXP beads                   | NEBDNA           | 10         |                                   |                      |                          |
| LG      | 1                 | ~350               | AMPureXP beads                   | TrueSeq DNA      | 0          |                                   |                      |                          |
| LH      | 0.5               | ~175               | AMPureXP beads                   | SureSelect WGS   | 10         |                                   |                      |                          |



## Ejemplo de variant calling: Cáncer



Contrariamente a lo que se piensa identificar variantes somáticas de datos WGS es todavía un gran reto.

## Ejemplo de variant calling: Cáncer

Table 3 | Summary of accuracy measures.

| SSM calls        | Aligner   | SSM Detection Software             | TP        | FP    | FN  | P           | R           | F1          |
|------------------|-----------|------------------------------------|-----------|-------|-----|-------------|-------------|-------------|
| MB.GOLD          | BWA, GEM  | Curated                            | 1,255 (8) | 0     | 0   | 1.00        | 1.00        | 1.00        |
| MB.A             | BWA       | In-house                           | 775 (0)   | 147   | 480 | 0.84        | 0.62        | 0.71        |
| MB.B             | BWA       | samtools, Varscan                  | 788 (1)   | 12    | 467 | 0.99        | 0.63        | 0.77        |
| MB.C             | GEM       | samtools, bcftools                 | 766 (3)   | 1,025 | 489 | 0.43        | 0.61        | 0.50        |
| MB.D             | n.a.      | SMuFin                             | 737 (4)   | 1,086 | 518 | 0.41        | 0.59        | 0.48        |
| MB.E             | BWA       | SomaticSniper                      | 750 (4)   | 229   | 505 | 0.77        | 0.60        | 0.67        |
| MB.F             | BWA       | Strelka                            | 884 (2)   | 165   | 371 | 0.84        | 0.70        | 0.77        |
| MB.G             | BWA       | Caveman, Picnic                    | 899 (3)   | 140   | 356 | 0.87        | 0.72        | 0.78        |
| MB.H             | Novoalign | MuTect                             | 947 (3)   | 6,296 | 308 | 0.13        | <b>0.76</b> | 0.22        |
| MB.I             | BWA       | samtools                           | 879 (7)   | 129   | 376 | 0.87        | 0.70        | 0.78        |
| MB.J             | None, BWA | SGA + freebayes                    | 856 (1)   | 62    | 399 | 0.93        | 0.68        | <b>0.79</b> |
| MB.K             | BWA       | Atlas2-snp                         | 945 (8)   | 7,923 | 310 | 0.11        | 0.75        | 0.19        |
| MB.L1            | BWA       | MuTect, Strelka                    | 385 (0)   | 3     | 870 | <b>0.99</b> | 0.31        | 0.47        |
| MB.L2            | BWA       | MuTect, Strelka                    | 900 (1)   | 253   | 355 | 0.78        | 0.72        | 0.75        |
| MB.M             | BWA, mem  | samtools, GATK + MuTect            | 937 (4)   | 1,695 | 318 | 0.36        | 0.75        | 0.48        |
| MB.N             | BWA       | Strelka                            | 847 (1)   | 289   | 408 | 0.75        | 0.68        | 0.71        |
| MB.O             | BWA       | MuTect                             | 944 (3)   | 272   | 311 | 0.78        | 0.75        | 0.76        |
| MB.P             | BWA       | Sidron                             | 833 (3)   | 256   | 422 | 0.77        | 0.66        | 0.71        |
| MB.Q             | BWA       | qSNP + GATK                        | 842 (2)   | 25    | 413 | 0.97        | 0.67        | <b>0.79</b> |
| <b>SIM calls</b> |           |                                    |           |       |     |             |             |             |
| MB.GOLD          | BWA, GEM  | Curated                            | 337 (10)  | 0     | 0   | 1.00        | 1.00        | 1.00        |
| MB.A             | BWA       | In-house                           | 16 (0)    | 63    | 321 | 0.20        | 0.05        | 0.08        |
| MB.B             | BWA       | GATK SomaticIndelDetector, Varscan | 167 (0)   | 20    | 173 | 0.89        | 0.49        | 0.63        |
| MB.C             | GEM       | samtools, bcftools                 | 103 (0)   | 26    | 236 | 0.80        | 0.30        | 0.44        |
| MB.D             | none      | SMuFin                             | 29 (0)    | 25    | 308 | 0.54        | 0.09        | 0.15        |
| MB.F             | BWA       | Strelka                            | 147 (8)   | 12    | 193 | 0.93        | 0.43        | 0.58        |
| MB.G             | BWA       | Pindel                             | 189 (2)   | 82    | 152 | 0.70        | 0.55        | 0.61        |
| MB.H             | Novoalign | VarScan2                           | 55 (0)    | 248   | 282 | 0.18        | 0.16        | 0.17        |
| MB.I             | BWA       | Platypus                           | 271 (7)   | 224   | 70  | 0.55        | <b>0.79</b> | <b>0.65</b> |
| MB.J             | None      | SGA                                | 90 (1)    | 34    | 249 | 0.72        | 0.26        | 0.38        |
| MB.K             | BWA       | Atlas2-indel                       | 268 (6)   | 444   | 72  | 0.38        | 0.79        | 0.51        |
| MB.L1            | BWA       | Strelka                            | 64 (1)    | 3     | 273 | <b>0.96</b> | 0.19        | 0.32        |
| MB.L2            | BWA       | Strelka                            | 130 (3)   | 13    | 210 | 0.91        | 0.38        | 0.53        |
| MB.N             | BWA       | Strelka                            | 128 (6)   | 16    | 209 | 0.89        | 0.38        | 0.53        |
| MB.O             | BWA       | GATK SomaticIndelDetector          | 140 (1)   | 47    | 197 | 0.75        | 0.42        | 0.53        |
| MB.P             | BWA       | bcftools, PolyFilter               | 37 (0)    | 57    | 301 | 0.39        | 0.11        | 0.17        |
| MB.Q             | BWA       | Pindel                             | 100 (2)   | 61    | 237 | 0.63        | 0.30        | 0.40        |

FL, F1 score; FN, false negative; FP, false positive; P, precision; R, recall; TP, true positive.  
Shown are the evaluation results with respect to the medulloblastoma Gold Set (Tier 3). Shown are the number of true calls (TP) with additional Tier 4 calls in parentheses, the number of FP, the number of FN, P, R and F1. The submissions with the best precision, recall and F1 score are in bold.

Alioto et al Nature Communications 2015


- Llamada a variantes con diferentes pipelines y datos de diferentes librerías da lugar a un bajo consenso.
- Checklist para estudios WGS en cáncer:
  - Preparar librería PCR-free
  - Tumor coverage 100x
  - Control coverage close to tumor coverage (+/-10%)
  - Reference genome hs37d5 o GRCh38
  - Combinación de alineador/variant caller optimo
  - Combinar varios llamadores de mutaciones
  - Permitir mutaciones en zonas repetidas o cerca de repeticiones.
  - Filtrado por calidad de mapado, strand bias, positional bias, presencia de soft-clipping

## Ejemplo de variant calling: TRIOS

- Formato: fastq
- Plataforma: HiSeq Illumina, 2x101
- Carreras: 1
- Lanes: 2 y 8
- Kit Enriquecimiento: TruSeq Exome Enrichment Kit (2011)

| Pedigrí | Sexo | Afectado |
|---------|------|----------|
| Padre   | V    | N        |
| Madre   | M    | N        |
| Hijo    | V    | S        |

# Variant Calling



Best Practices for Germline SNPs and Indels in Whole Genomes and Exomes - June 2016



## Postprocesamiento y QC alineamiento

- Filtrado de duplicados: Picard
  - Análisis de la calidad del BAM
  - Recalibración de variantes
  - Realineamiento
- } GATK

| Sample | Target Specificity | Target Enrichment | Mean Coverage | SD Coverage | 5X  | 10X | 20X | 30X |
|--------|--------------------|-------------------|---------------|-------------|-----|-----|-----|-----|
| Padre  | 0.77               | 39.40             | 90.92         | 79.87       | 95% | 93% | 90% | 85% |
| Madre  | 0.78               | 39.85             | 72.68         | 64.91       | 93% | 92% | 87% | 81% |
| Hijo   | 0.78               | 39.78             | 60.46         | 53.12       | 93% | 90% | 84% | 75% |


# Variant Calling: Realineamiento

## Realineamiento local de múltiples secuencias

Proporciona un **alineamiento consistente** entre todas las lecturas. Se identifican las **regiones susceptibles de realineamiento**, si:

- Al menos una lectura contiene un **indel**
- Existe un **cluster de bases mismatch**
- Existe un **indel conocido**

Before



After






## Variant Calling: Realineamiento

### Score de calidad de una base


Probabilidad de que la base determinada sea verdadera (y no un error de secuenciación).

- En escala *Phred*.  $Q = -10 \cdot \log_{10} P$
- Se codifica en ASCII (normalmente  $Q+33$ )
- Se estima de un modo muy inexacto porque sigue un esquema de correlación complejo entre la tecnología de secuenciación, el ciclo de máquina y el contexto de secuencia.



Los errores de mapeo y la inexactitud de los scores de calidad se propagan a la etapa de identificación de variantes y genotipado

# Variant Calling: HaplotypeCaller



- Determina si una región es potencialmente variable
- Construye un ensamblado de Bruijn de la región.
- Los “paths” en el grafo son haplotipos potenciales que tienen que ser evaluados.
- Se calcula los likelihoods de los haplotipos dados los datos usando un modelo PairHMM.
- Determina si hay alguna variante entre los haplotipos más probables.
- Calcula la distribución de la frecuencia alélica para determinar el conteaje de alelos más probables y emite una variante si se da el caso.
- Si se emite una variante se calcula el genotipo para cada muestra.

## Estadísticas del filtrado

| Variants | Raw    | HardFiltering* | GenotypeRefinement | Quality Filtering |
|----------|--------|----------------|--------------------|-------------------|
| SNPs     | 294018 | 189031         | 188910             | 177660            |
| INDELs   | 40677  | 27695          | 26646              |                   |

\*Siendo este número aquellas variantes marcadas como PASS después del filtrado.


## Modelos de Enfermedad

- Modelo de novo
- Modelo double-hit gene
- Modelo Recesivo
- Modelo dominante

Seleccionamos estos dos como los más probables en nuestro caso.

## Modelos de enfermedad

- Modelo de novo




## Modelo de novo

- Filtros ad-hoc
  - Primera aproximación:
    - FILTER = PASS
    - Genotipo =

Padre 0/0


Madre 0/0

Hijo 0/1 o 1/0



## Modelos de enfermedad

- Modelo double-hit gene



## Modelo double-hit gene

- Filtros ad-hoc


- Primera aproximación:

- FILTER = PASS
    - Filtro por missense, frameshift, splicing o stop-gain
    - Mutation taster: A o D
    - Genotipo =

Padre 0/1

Madre 0/1


Hijo 1/1





## Modelo double-hit gene

GDPD4



- Glycerophosphodiester Phosphodiesterase domain-containing 4
- Proteína de membrana
- Relacionada con el metabolismo de glicerofosfolípidos.
- Relacionado mutaciones en este gen con el síndrome del shock tóxico (TSS).
- Variantes vistas en el gen:
  - Delección patogénica en el cromosoma 11 71680927-7794394
  - Relacionado con retraso en el desarrollo y fenotipos morfológicos significativos.


## Modelo double-hit gene

GDPD4

Padre

Madre

Hijo




## Modelo double-hit gene

### • Filtros ad-hoc

- Segunda aproximación:
  - FILTER = PASS
  - Filtro por missense, frameshift, splicing o stop-gain
  - Mutation taster: A o D
  - Genotipo =

|       |     |     |
|-------|-----|-----|
| Padre | 1/0 | 0/0 |
| Madre | 0/0 | 1/0 |
| Hijo  | 0/1 | 0/1 |



## Modelo double-hit gene

NBPF1

| Chromosome | StartPosition | Reference<br>AlternativeAllele | rsID                      | MostImportantFeatureGene | MostImportantGeneFeature  | GeneDescription                                      |
|------------|---------------|--------------------------------|---------------------------|--------------------------|---------------------------|------------------------------------------------------|
| 1          | 16890484      | G/C                            | rs12117084<br>(suspected) | NBPF1                    | missense<br>(cys -> ser ) | neuroblastoma breakpoint family, member 1 (Approved) |
| 1          | 16909134      | G/A                            | .                         | NBPF1                    | missense                  |                                                      |

### Mutación en el 5% de los reads

En madre e hijo. Posibles errores de alineamiento por tratarse de genes duplicados.

- Gen de la familia “breakpoint” de neuroblastoma. Docenas de genes duplicados localizados en duplicaciones segmentales en el cromosoma 1.
- Cambios en el número de copia se ha relacionado con enfermedades del desarrollo y neurogenéticas como microcefalia, macrocephalia, autismo, retraso mental, neuroblastoma, enfermedades del corazón congénitas, etc.

## Creación de estándares

### College of American Pathologists' Laboratory Standards for Next-Generation Sequencing Clinical Tests

*Nazneen Aziz, PhD; Qin Zhao, PhD; Lynn Bry, MD, PhD; Denise K. Driscoll, MS, MT(ASCP)SBB; Birgit Funke, PhD;  
Jane S. Gibson, PhD; Wayne W. Grody, MD; Madhuri R. Hegde, PhD; Gerald A. Hoeltge, MD; Debra G. B. Leonard, MD, PhD;  
Jason D. Merker, MD, PhD; Rakesh Nagarajan, MD, PhD; Linda A. Palicki, MT(ASCP); Ryan S. Robetorye, MD; Iris Schrijver, MD;  
Karen E. Weck, MD; Karl V. Voelkerding, MD*

- Recomendaciones en documentación, trazabilidad, validación, almacenamiento, ...
  - Extracción de ADN
  - Preparación de librerías
  - Referencias y versiones
  - Pipeline bioinformático de análisis

# Creación de estándares

## Interpretación de variantes.

**Table 5**

Rules for Combining Criteria to Classify Sequence Variants

| <u>Pathogenic</u>        |                                                                            |
|--------------------------|----------------------------------------------------------------------------|
| 1                        | 1 Very Strong (PVS1) <i>AND</i>                                            |
|                          | a. $\geq 1$ Strong (PS1–PS4) <i>OR</i>                                     |
|                          | b. $\geq 2$ Moderate (PM1–PM6) <i>OR</i>                                   |
|                          | c. 1 Moderate (PM1–PM6) and 1 Supporting (PP1–PP5) <i>OR</i>               |
|                          | d. $\geq 2$ Supporting (PP1–PP5)                                           |
| 2                        | $\geq 2$ Strong (PS1–PS4) <i>OR</i>                                        |
| 3                        | 1 Strong (PS1–PS4) <i>AND</i>                                              |
|                          | a. $\geq 3$ Moderate (PM1–PM6) <i>OR</i>                                   |
|                          | b. 2 Moderate (PM1–PM6) <i>AND</i> $\geq 2$ Supporting (PP1–PP5) <i>OR</i> |
|                          | c. 1 Moderate (PM1–PM6) <i>AND</i> $\geq 4$ Supporting (PP1–PP5)           |
| <u>Likely Pathogenic</u> |                                                                            |
| 1                        | 1 Very Strong (PVS1) <i>AND</i> 1 Moderate (PM1–PM6) <i>OR</i>             |
| 2                        | 1 Strong (PS1–PS4) <i>AND</i> 1–2 Moderate (PM1–PM6) <i>OR</i>             |
| 3                        | 1 Strong (PS1–PS4) <i>AND</i> $\geq 2$ Supporting (PP1–PP5) <i>OR</i>      |
| 4                        | $\geq 3$ Moderate (PM1–PM6) <i>OR</i>                                      |
| 5                        | 2 Moderate (PM1–PM6) <i>AND</i> $\geq 2$ Supporting (PP1–PP5) <i>OR</i>    |
| 6                        | 1 Moderate (PM1–PM6) <i>AND</i> $\geq 4$ Supporting (PP1–PP5)              |
| <u>Benign</u>            |                                                                            |
| 1                        | 1 Stand-Alone (BA1) <i>OR</i>                                              |
| 2                        | $\geq 2$ Strong (BS1–BS4)                                                  |
| <u>Likely Benign</u>     |                                                                            |
| 1                        | 1 Strong (BS1–BS4) and 1 Supporting (BP1–BP7) <i>OR</i>                    |
| 2                        | $\geq 2$ Supporting (BP1–BP7)                                              |

\* Variants should be classified as Uncertain Significance if other criteria are unmet or the criteria for benign and pathogenic are contradictory.

Standards and Guidelines for the Interpretation of sequence variants. American College of Medical Genetics and Genomics. Association for Molecular Pathology. 2015

## Ejemplo de variant calling: Bacterias

- Identificación de Brotes de origen alimentario, “Crisis del Pepino”

2011

Mayo

- 24 Primera muerte en Alemania
- 26 Alemania acusa a los pepinos españoles
- 30 Prohibición de importaciones de verduras de España y Alemania
- 31 Laboratorios alemanes desmienten oficialmente que los pepinos españoles sean el foco de infección

Junio

- 10 Resolución de la crisis

Causado por la toxi-infección de *Escherichia coli* enterohemorrágica (EHEC) (*Escherichia coli* O104:H4)

Muerte: 32 personas en Alemania, 1 Suecia y 1 Francia y 2263 infectados en 12 países de Europa.

Crisis Política y Económica Europa: Alto impacto en la Economía Europea, mayor afectación en la Española

Secuenciación Genoma

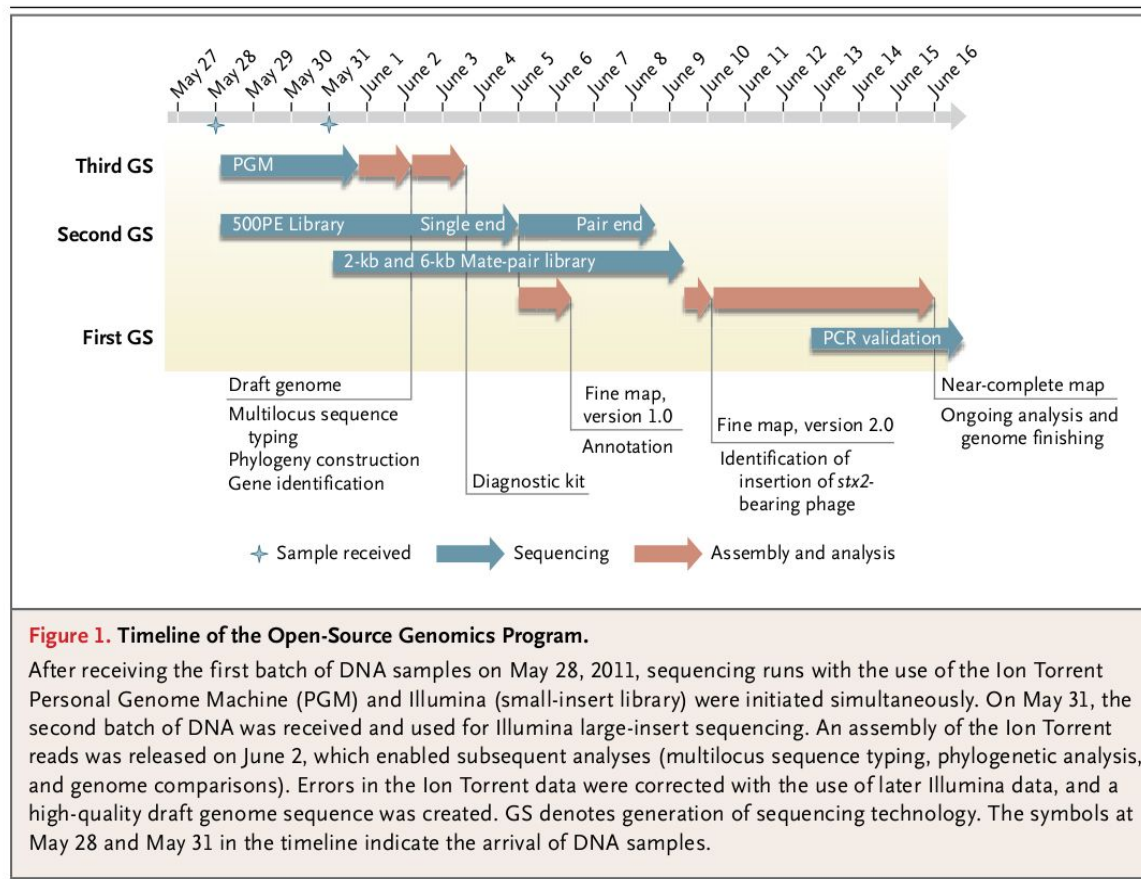
华大基因  
BGI



Universitätsklinikum  
Hamburg-Eppendorf

## Ejemplo de variant calling: Bacterias


- Identificación de Brotes de origen alimentario, “Crisis del Pepino”






## Ejemplo de variant calling: Bacterias

- Identificación de Brotes de origen alimentario, “Crisis del Pepino”



## Pipeline variant calling: Bacterias



## Software disponible

- CFSAN SNP Pipeline

Extracción de SNPs de alta calidad de aislados relacionados

<http://snppipeline.readthedocs.io/en/latest/>

- GATK, modo haploide
- Samtools
- Varscan
- Snippy

Identificación de variantes haploides y construcción de filogenia usando core genome SNPs


<http://github.com/tseemann/snippy>

- Live-SET

High-quality SNPs para crear filogenia para investigación de brotes

<https://github.com/lskatz/lyve-SET>

## Generación de matriz de SNPs




## Generación de matriz de SNPs

SNP matrix

| SNP 1 | SNP 2 | SNP 3 |           |
|-------|-------|-------|-----------|
| A     | G     | C     | Reference |
| T     | C     | C     | Sample 1  |
| T     | G     | A     | Sample 2  |
|       |       |       | Sample n  |


Phylogeny



## Ejemplo de llamada a variantes: Virus


IRMA: Iterative Refinement Meta-Assembler

A



Shepard et al BMC Genomics 2016, **17**:708

## Ejemplo de llamada a variantes: Virus



Shepard et al BMC Genomics 2016, **17**:708

# ¿Preguntas?

---